

一、研究背景及意义

信息检索技术是支撑现代搜索引擎、知识库系统及检索增强生成等智能应用的核心基石。随着数字化进程的加速，海量文档已成为机构与个人知识资产的主要载体，如何从中高效、精准地定位所需信息，直接关系到决策效率与知识服务的质量。在检索技术持续发展的进程中，视觉语言模型正成为推动其范式变革的关键驱动力。传统文档检索系统长期依赖于“文本”这一单一模态，其典型流程涉及 OCR 识别、布局解析、文本分块与嵌入索引等多个串行环节。这种以文本为中心的范式虽广泛应用，但存在固有局限：首先，其性能严重受制于前端处理流程的可靠性，OCR 错误、布局误判、非文本元素丢失等问题会直接导致检索质量下降；其次，冗长的预处理管道带来了高昂的计算与时间成本，制约了大规模文档库的构建与更新效率；最后，对于图表、信息图、特定版式等视觉信息丰富的文档，纯文本检索难以充分捕捉其语义，无法满足用户对多模态内容的精准查询需求。因此，探索能够直接理解文档视觉内容的新颖检索范式，已成为突破现有技术瓶颈的必然方向。

为系统评估视觉文档检索技术的进展，研究领域提出了 ViDoRe (Visual Document Retrieval Benchmark) 基准。该基准涵盖多领域、多语言、多模态的页面级检索任务，其评估结果清晰表明：即使为传统流程集成最先进的 OCR 与图像描述技术，其性能提升也主要源于对视觉信息的“文本化”补偿，且伴随着难以承受的效率代价。这深刻揭示了现有技术范式的天花板。在此背景下，本研究所研讨的论文《ColPali: Efficient Document Retrieval with Vision Language Models》提出了一种革命性的解决方案——**基于视觉语言模型，直接对文档页面图像进行编码与检索**。该研究通过发布 ColPali 模型，实证了绕过脆弱中间步骤、实现端到端视觉检索的可行性，为领域发展指明了新路径。然而，将这一前沿理念转化为稳定、高效的实用系统，仍需在模型适配、效率优化、评估体系等方面进行深入探索。

因此，面向视觉丰富文档的高效检索研究，正处于从传统文本范式向多模态端到端范式转型的关键阶段，尚存在若干核心挑战需予以攻克：第一，**模型感知与匹配的深度不足**。现有方法虽能利用视觉语言模型，但如何使其精准理解文档中复杂的版面结构、图表关系及文字与视觉元素的语义关联，避免陷入对表面纹理或风格的“捷径学习”，仍需更强大的跨模态对齐与推理机制。第二，**效率与性能的平衡难题**。端到端视觉检索需处理高分辨率图像，对计算资源与响应延迟提出挑战；如何在保障高检索精度的同时，实现模型轻量化与检索过程的加速，是决定其能否落地应用的关键。第三，**评估与验证体系尚不完善**。尽管 ViDoRe 基准提供了重要起点，但针对不同领域文档特性、不同退化条件（如扫描质量差、拍摄畸变）下的模型鲁棒性评估，以及超越检索精度的可解释性、公平性等维度衡量，仍需建立更全面的标准。第四，**技术路径与工程实践的整合间隙**。从前沿论文到可复现、可扩展、易集成的检索系统，中间

涉及大量工程优化、数据预处理与部署适配工作，需要系统的实践探索来弥合理论与应用之间的鸿沟。

综上所述，本研究立足《ColPali: Efficient Document Retrieval with Vision Language Models》这一前沿工作，以“基于视觉语言模型的高效文档检索”为课题，旨在深入探究并实践端到端视觉文档检索的新范式。针对模型深度感知不足的问题，开展视觉语言模型在文档结构理解上的适配与增强研究；针对效率瓶颈，进行模型轻量化与检索加速机制研究；针对评估体系短板，构建更贴近真实场景的鲁棒性评测方案；针对工程化间隙，完成从原型到可运行系统的完整实现与优化。因此，本研究拟突破传统检索局限，探索前沿智能检索系统，具有显著的理论价值与实践意义。

二、国内外研究现状

（1）受损文档的预处理与增强

在通用模型方面，华南理工大学提出的 DocRes 与中国科学院信息工程研究所研发的 Uni-DocDiff 是代表性工作[1,2]。它们通过引入动态任务提示或可学习的先验机制，将多种复原任务统一于单一模型，显著提升了系统的便捷性与可扩展性，但其在应对极端复杂或耦合退化时，性能有时仍不及高度特化的专家模型。而在任务特异性方面，研究侧重于将复原与下游应用深度结合。例如，都柏林圣三一学院的 PreP-OCR 通过合成退化数据训练复原模型，并串联语义后校正，专为提升历史文档的 OCR 精度设计[3]。而哈尔滨工业大学的研究则创新性地利用跨模态引导（图像-文本-图像），在通用图像复原任务上表现优异[4]。然而，此类方法的效果严重依赖于合成数据与真实分布的对齐度，或受限于跨模态对齐模型的能力，在处理具有复杂视觉结构的文档或未知退化类型时泛化能力不稳定。

综合来看，尽管一体化复原已成为趋势[5]，现有方法仍缺乏对真实世界中多种退化因素耦合机制的可解释建模，其合成的数据分布与复杂的真实域间差异存在鸿沟，导致模型在开放场景下的鲁棒性不足，难以满足下游检索任务对特征高度一致性的要求。

三、研究内容与技术路线

1. 研究内容

（1）研究内容一：面向视觉文档检索的退化图像合成与前端复原

真实世界中的文档图像常受到多种物理因素的综合影响，呈现出光照不均、运动模糊、透视畸变、墨迹洇染、低分辨率及 JPEG 压缩等复杂退化形态，这些退化往往并非孤立出现，而是以耦合叠加的方式共同作用于同一图像，使得退化过程的建模与复原均面临较大挑战。此外，文档类型的多样性——从标准化的企业报表、政府表单

到版式自由的学术论文及历史扫描档案——本身亦构成显著的域间分布差异，进一步加剧了图像质量对视觉语言模型感知能力的干扰。现有预处理方法多针对单一退化类型设计独立的后处理流程，难以有效应对多退化耦合场景，而通用图像增强方法又容易在提升视觉质量的同时破坏文档特有的字符形态与版面结构语义，得不偿失。

针对上述问题，本研究内容拟围绕退化图像的可控合成与前端复原展开。在数据层面，拟构建一个统一的参数化文档退化合成管线，将几何形变（透视变换、旋转）、模糊（运动模糊、散焦模糊）、噪声（高斯噪声、椒盐噪声）、色彩偏移及分辨率退化等物理因素参数化，使得各类退化的类型与强度均可通过参数精确控制，从而以 ViDoRe 基准的干净文档图像为原始素材，批量生成覆盖多种退化组合的合成受损数据集，为后续实验提供可控、可解释的训练与评估样本。在复原层面，拟研究面向文档场景的轻量级前端复原网络，探索其能否在退化类型估计的引导下自适应地选择复原路径，使同一网络对噪声、模糊、畸变等不同退化类型均具备有效的处理能力，而非为每类退化单独训练一个专用模型。与此同时，本研究拟重点考察复原操作在保留文档字符形态与版面结构语义方面的边界——对检索任务而言，视觉质量的提升是否必然带来检索性能的改善，两者之间的解耦关系亦是本研究内容期望厘清的核心问题之一。

（2）研究内容二：面向受损文档的视觉语言模型鲁棒性增强

即便在前端复原之后，图像中仍可能残留难以完全消除的退化痕迹，或因复原操作本身引入新的伪影而影响后续模型的嵌入质量。更根本的问题在于，ColPali 等视觉语言模型在训练阶段所使用的文档图像绝大多数为高质量的数字原生 PDF 截图，其特征分布与退化文档存在系统性差异，导致模型在编码退化图像时倾向于将退化相关的表面外观纳入多向量表示，而非聚焦于文档的语义内容与版面结构。这一问题无法仅凭前端图像处理完全化解，需要在模型的表示学习层面加以应对。

本研究内容拟在视觉语言模型的编码阶段引入退化不变性增强机制，使模型在面对受损文档时仍能生成与干净版本高度一致的语义嵌入表示。拟探索的技术路径主要包含以下几个方向：其一，拟研究基于对比学习的退化不变特征学习策略，通过构造同一文档页面在干净与退化条件下的正样本对，在训练过程中显式拉近两者的 Patch 嵌入距离，使模型习得对退化噪声的不敏感性；其二，拟考察在编码器中引入风格归一化或域对抗训练模块的可行性，迫使中间层特征的分布在不同退化条件下保持一致，从而将退化因素从语义特征中解耦分离；其三，由于 ColPali 的延迟交互得分

$$s_{\mathcal{M}}(q, d) = \sum_{i=1}^{N_q} \max_{j \in \mathcal{M}(d)} \langle q_i, d_j \rangle$$

对每个文档 Patch 均赋予独立的检索贡献，退化严重的 Patch 可能产生误导性的高相似度响应，本研究拟探索在延迟交互计算阶段引入退化感知的 Patch 置信度加权机制，动态降低低质量 Patch 对最终检索得分的影响权重，以期在不修改模型主干参数的前提下提升检索鲁棒性。上述增强策略的有效性拟在研究内容一所构建的合成退化数据集上进行系统验证，并通过干净图像—退化图像—增强后三组条件的对比实验评估各方案对检索性能的改善幅度。

2. 研究目标

强化对退化文档的鲁棒感知能力：针对真实场景中复杂耦合的图像退化与跨域分布偏移问题，本研究旨在建立统一、可控的文档图像退化模型，并发展退化不变的特征学习策略。核心目标是使模型能够剥离由设备、环境与载体老化引入的外观干扰，实现对文档版面结构与语义内容的稳定、一致理解，为后续高效检索奠定鲁棒的视觉感知基础。

3. 拟采取的技术路线

受损文档图像的预处理与增强的技术路线

本研究拟以 ViDoRe 基准的标准测试图像为基础素材，通过程序化方式批量合成多类型、多强度的退化图像，从而在完全可控的条件下系统评估各类图像损伤对 ColPali 检索性能的影响。计划涵盖的退化类型主要包括高斯噪声、运动模糊、JPEG 有损压缩以及几何倾斜四类。从信号处理的角度看，上述退化过程可统一建模为 $\mathbf{y} = \mathbf{H}\mathbf{x} + \mathbf{n}$ ，其中 $\mathbf{x}$ 为原始干净图像， $\mathbf{H}$ 为退化算子（对模糊退化而言对应卷积核，对几何倾斜而言对应仿射变换矩阵）， $\mathbf{n}$ 为加性噪声项。每种退化类型均拟设置若干强度梯度，以期获得退化程度与性能损失之间的连续变化规律，而非单一对比。在实现层面，计划借助 OpenCV 与 PIL 等成熟的图像处理库完成退化操作，并通过固定随机种子保证实验的可复现性，最终形成与 ViDoRe 原始测试集一一对应的多版本退化图像库。

在图像复原方面，本研究拟针对不同退化类型分别引入适配的前置处理方法，而非采用单一的通用方案。对于噪声类退化，拟考察从传统的高斯滤波、双边滤波、非局部均值到基于深度学习的去噪网络（如 DnCNN 或 FFDNet）等多种方案在文档图像场景下的实际效果，并探明算法复杂度与性能修复幅度之间的权衡关系。对于模糊与压缩失真，拟尝试引入轻量级图像超分辨率或复原模型（如 ESRGAN 或 BSRGAN 的轻量化变体），这类模型已有较成熟的开源实现，预期可在消费级 GPU 上完成离线批

处理而无需承担过多算力压力。对于几何倾斜问题，拟考虑基于 Hough 变换或投影轮廓分析的自动倾斜校正方案，对文档进行去旋转预处理后再送入 ColPali 流程。所有预处理操作均计划以离线批处理的方式提前完成，将处理结果存储为图像文件，从而与后续的向量提取流程解耦，避免引入额外的在线计算负担。

在实验评估层面，本研究拟通过三组系统性对比来量化各阶段的性能变化：以原始干净图像上的检索结果作为性能基线，以退化图像上的结果刻画各类损伤的影响程度，以复原后图像上的结果评估预处理的修复效果。为衡量复原操作在检索层面的实际收益，拟定义复原增益指标：

$$\Delta nDCG^{(k)}(\lambda) = nDCG(\hat{\mathbf{x}}_{\lambda}) - nDCG(\mathbf{y}^{(k)})$$

，其中 k 为退化类型， λ 为复原强度参数， $\hat{\mathbf{x}}_{\lambda}$ 为以强度 λ 复原后的图像。通过对不同 λ 绘制该指标的变化曲线，可直观呈现 ColPali 对不同退化类型的敏感度差异，并为技术路线四的参数寻优提供先验输入。

四、组员分工与进度计划

1. 组员分工

(1) **廖锐焯**：负责退化文档数据集的可控合成与退化敏感性基准评估。主要任务聚焦于研究内容一的数据基础建设。具体工作包括：基于 ViDoRe 基准的干净文档图像，设计并实现参数化的多退化合成管线，将透视畸变、运动模糊、高斯噪声、JPEG 压缩、低分辨率及色彩偏移等物理退化因素统一编码为可调参数，支持单一退化与多退化耦合的可控生成，最终形成覆盖常见真实场景的分级退化数据集；在此基础上，以 ViDoRe 标准检索指标（nDCG@5 等）为基准，系统评估各退化类型及其强度梯度对 ColPali 检索性能的影响，绘制“退化强度—性能退化”曲线，为后续复原方案的必要性论证与效果评估提供量化基线。

(2) **王昱皓**：负责轻量级前端复原网络的集成测试与“复原—检索”解耦分析。主要任务聚焦于研究内容一的复原方法部分。具体工作包括：集成并测试现有轻量级图像复原模型（包括去噪网络 DnCNN/FFDNet、超分辨率模型 ESRGAN 轻量化变体等）对廖锐焯构建的退化数据集的处理效果，探索基于退化类型估计自适应选择复原路径的可行性，使同一前端框架能应对多种退化类型而无需逐类单独部署；重点研究并实验验证“图像视觉质量提升是否必然带来检索性能改善”这一关键问题，通过对原始、退化、复原后三组条件下 ColPali 的 Patch 嵌入分布与检索得分的对比分析，揭示复原操作对文档字符形态与版面结构语义的保留程度，从而厘清前端复原在整体流程中的实际贡献边界。

(3) **何青泽**：负责退化不变特征学习策略的研究与验证。主要任务聚焦于研究内容二的表示学习方向。具体工作包括：研究基于对比学习的退化不变性增强方案，以同一文档页面的干净版本与退化版本构造正样本对，通过在训练阶段显式拉近两者的

Patch 嵌入距离，使 ColPali 的多向量表示对退化噪声具备主动的不敏感性；进一步探索在视觉语言模型编码器中引入风格归一化或域对抗训练模块的可行性，考察其能否在中间层特征层面将退化因素与语义内容解耦分离；基于廖锐煊构建的合成退化数据集设计严格的对比实验，评估上述特征增强策略对检索鲁棒性的改善幅度，并分析不同策略在计算开销与性能增益之间的权衡关系。

（4）**郭明坤：负责退化感知的延迟交互加权机制设计与整体评估。**主要任务聚焦于研究内容二的推理增强方向及全流程评估。具体工作包括：基于 ColPali 延迟交互得分的计算机制，研究在推理阶段引入退化感知的 Patch 置信度加权方案，动态降低因退化严重而携带误导性响应的低质量 Patch 对最终检索得分的贡献权重，以期在不修改模型主干参数的前提下提升检索鲁棒性；同时负责研究内容一与研究内容二的整体评估框架设计，构建融合检索精度（nDCG@5、MRR）、计算延迟与存储代价的多维度评估体系，对两项研究内容下各方案进行统筹横向比较，并通过帕累托前沿分析为整体流程的参数配置提供系统性建议。

2.进度计划

按照课程安排，该课程将进行至本学期第 9 周。以下以周为单位，为每周的工作内容呈现一个初步的进度计划：

第 5 周：数据准备与基线实验。全体成员在本周内，基于提供的基准测试集（如 ViDoRe）和已构建的退化数据，复现或运行 ColPali 基线模型，获得初始性能结果，确认实验环境与流程无误。

第 6 周：核心方法并行实验。基于基线结果，系统评估不同图像预处理方法对检索性能的影响，并输出初步分析报告。

第 7 周：结果分析与方案优化。各成员深入分析第 6 周实验结果，识别当前方法的优势与不足。基于分析结果，对各自负责的方法进行一轮优化与调整。进行优化后的对比实验，验证改进效果。开始初步整合各模块，进行简单的流程测试。

第 8 周：系统集成与综合测试。将经过优化的预处理模块、分割模块与检索模型进行完整集成，构建统一的实验流水线。在最终的集成系统上，使用统一的评估框架，对构建的多种数据集进行全面的综合测试。

第 9 周：报告撰写与成果整理。全体成员协作，依据实验数据与分析结论，撰写完整的课程设计报告。准备最终汇报所需的演示文稿、图表及代码文档。完成项目总结，并提交所有要求的材料。

五、参考文献

- [1]Zhang, Jiaxin, et al. "Docres: A generalist model toward unifying document image restoration tasks." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024.
- [2]Zhao, Fangmin, et al. "Uni-DocDiff: A Unified Document Restoration Model Based on Diffusion." Proceedings of the 33rd ACM International Conference on Multimedia. 2025.
- [3]Guan, Shuhao, et al. "Prep-OCR: a complete pipeline for document image restoration and enhanced OCR accuracy." Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2025.
- [4]Lin, Jingbo, et al. "Improving image restoration through removing degradations in textual representations." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024.
- [5]Jiang, Junjun, et al. "A survey on all-in-one image restoration: Taxonomy, evaluation and future trends." IEEE Transactions on Pattern Analysis and Machine Intelligence (2025).
- [6]Liu, Chuanhong, et al. "Adaptable semantic compression and resource allocation for task-oriented communications." IEEE Transactions on Cognitive Communications and Networking 10.3 (2023): 769-782.
- [7]Gilbert, Henry, et al. "Semantic compression with large language models." 2023 Tenth International Conference on Social Networks Analysis, Management and Security (SNAMS). IEEE, 2023.
- [8]Li, Shengxi, et al. "Hierarchical Semantic Compression for Consistent Image Semantic Restoration." IEEE Transactions on Image Processing (2025).
- [9]Li, Chunyi, et al. "Misc: Ultra-low bitrate image semantic compression driven by large multimodal model." IEEE Transactions on Image Processing 34 (2024): 335-349.
- [10]Li, Nan, Alexandros Iosifidis, and Qi Zhang. "Dynamic semantic compression for cnn inference in multi-access edge computing: A graph reinforcement learning-based autoencoder." IEEE Transactions on Wireless Communications (2024).
- [11] Du, Xuefeng, et al. "Vos: Learning what you don't know by virtual outlier synthesis." arXiv preprint arXiv:2202.01197 (2022).
- [12] Ming, Yifei, and Yixuan Li. "How does fine-tuning impact out-of-distribution detection for vision-language models?." International Journal of Computer Vision 132.2 (2024): 596-609.
- [13] Miyai, Atsuyuki, et al. "Locoop: Few-shot out-of-distribution detection via prompt learning." Advances in Neural Information Processing Systems 36 (2023): 76298-76310.

- [14] Wang, Hualiang, et al. "Clipn for zero-shot ood detection: Teaching clip to say no." Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023.
- [15] Bitterwolf, J., Müller, M., & Hein, M. In or out? fixing imagenet out-of-distribution detection evaluation. ICML, 2023.
- [16] Yang, Jingkang, Kaiyang Zhou, and Ziwei Liu. "Full-spectrum out-of-distribution detection." International Journal of Computer Vision 131.10 (2023): 2607-2622.
- [17] López-Ibáñez, Manuel, et al. "The irace package: Iterated racing for automatic algorithm configuration." Operations Research Perspectives 3 (2016): 43-58.
- [18] Li, Lisha, et al. "Hyperband: A novel bandit-based approach to hyperparameter optimization." Journal of machine learning research 18.185 (2018): 1-52.
- [19] Falkner, Stefan, Aaron Klein, and Frank Hutter. "BOHB: Robust and efficient hyperparameter optimization at scale." International conference on machine learning. PMLR, 2018.
- [20] Lorraine, J., Vicol, P., & Duvenaud, D. Optimizing millions of hyperparameters by implicit differentiation. International Conference on Artificial Intelligence and Statistics, 2020.